Eduardo Bonet 3° Meetup Data Science Floripa

Python (vs) e R

Um Exemplo Prático

Bio

Bonet

Engenharia de Controle e Automação

"Mestrando" em Ciência da Computação

Full Stack, Mobile, Data Science

github.com/ebonet



Objetivos

Python (vs) **E** R : Não é uma competição

Resolver um problema simples com as duas linguagens.

Analisar algumas diferenças na hora do uso.

Código disponível em: https://github.com/ebonet/pythonandr

O Problema

Criar um modelo para preço de aluguel mensal em Floripa

Fonte de dados: http://api.vivareal.com/#!/listings

Etapas:

- Aquisição
- Processamento e Exploração
- Criação de modelo
- Visualização

Setup

Python 2.7.10

• IDE: PyCharm

Libs: SciPy, NumPY, Pandas, statsmodels

R 3.1.13

IDE: RStudio

• Libs: Rmisc, rjson, ggplot2, png

Aquisição (prepare.py)

Dados em JSON, query paginada

```
def perform_paged_request(page):
    url = "http://api.vivareal.com/api/1.0/locations/listings"
    params = {
        "apiKey": "183d98b9-fc81-4ef1-b841-7432c610b36e",
        "exactLocation": False,
        "currency": "BRL",
        "business": "RENTA",
        "listingType": "APART",
        "listingUse": "RESIDENCIAL",
        "rankingId":0,
        "locationIds": "BR>Santa Catarina>NULL>Florianopolis",
        "maxResults": 40,
        "page": page
}

response = requests.get(url, params=params)
    return json.loads(response.content)
```

```
def load data(out, max = 100):
    current_page = 1
    data = perform_paged_request(current_page)
    print data
    listings = []
    while current page < max and data and data["listings"]:
        print current page
       listings = listings+data["listings"]
        current page += 1
        data = perform paged request(current page)
    json.dump({"rentals": listings}, open(out, "w"))
load data("rentals.json")
```

Aquisição (prepare.R)

```
buildUrl <- function(page) paste(c("http://api.vivareal.com/api/1.0/locations/listings?",
           "apiKey=183d98b9-fc81-4ef1-b841-7432c610b36e&exactLocation=FALSE",
10
           "&currency=BRL&business=RENTA&listingType=APART&listingUse=RESIDENCIAL",
           "&rankingId=0&locationIds=BR%3ESanta%20Catarina%3ENULL%3EFlorianopolis",
11
12
          "&maxResults=40&page=", page), collapse="")
13
14 - loadData <- function(max=100) {
15
16
      all <- c()
17
18 -
      for (i in 0:max) {
19
        d <- fromJSON(file=buildUrl(i))</pre>
20
21
        if(length(d$listings) ==0)
22
          break
23
24
        all <- c(all, d$listings)
25
26
27
      all
28
29
    data <- loadData()
```

Conversão para CSV (prepare.py)

```
46
       def toCsv(inputF, outputF):
47
48
            rentals = json.load(inputF, encoding="utf-8")["rentals"]
49
           keys = ["propertyId", "rentPrice", "area", "bathrooms", "rooms",
50
                    "garages", "latitude", "longitude", "address", "suites",
51
                    "rentPeriodId", "condominiumPrice", "iptu"]
52
53
           writer = csv.DictWriter(outputF, encoding="utf-8", fieldnames=keys, quoting=csv.QUOTE_ALL)
54
           writer.writeheader()
55
           writer.writerows([{k:rental[k] for k in keys} for rental in rentals ])
```


Conversão para CSV (prepare.r)

```
32 - json2df <- function(data) {
      keys <- c("propertyId", "rentPrice", "area", "bathrooms", "rooms",
33
34
                 "garages", "latitude", "longitude", "address", "suites",
35
                 "rentPeriodId", "condominiumPrice", "iptu")
36
37
      # Black Magic to transform the list into a data frame
38
      k<- lapply(data, function(d){as.character.default(d[keys])})</pre>
      d <- as.data.frame(do.call(rbind, lapply(k, rbind)))</pre>
      d[d=="NULL"] <- NA
40
41
      names(d) <- keys
42
43
    dt <- json2df(data)
    write.csv(dt, file="rentals.csv", row.names=F)
47
```

Exploração (visualization.py)


```
33
34
        plt.figure();
        i@ = matplotlib.image.imread('flnp2.png');
35
        im[:,:,-1] = 0.7;
36
        plt.imshow(im, extent = [-48.68, -48.3, -27.85, -27.35]);
37
        plt.scatter(train_data.longitude,
38
                    train_data.latitude,
39
                    c = train data.rentPrice);
40
41
        plt.colorbar()
42
        plt.axis([-48.68, -48.3, -27.85, -27.35]);
43
        plt.title(u"Distribução dos Imóveis");
```





Exploração (visualization.R)

```
img <- readPNG("flnp2.png")
    img[,,4] <- 0.3
    ggplot(train_data, aes(x=longitude, y=latitude, color = rentPrice) ) +
      scale_colour_gradientn(
59
60
        colours=rev(rainbow(4)), quide = "colourbar") +
61
      annotation_custom(
        rasterGrob(img, width=unit(1, "npc"), height=unit(1, "npc")),
62
                        -Inf, Inf, -Inf, Inf) +
63
      coord_cartesian(klim = c(-48.68, -48.3), ylim = c(-27.85, -27.35)) +
64
      scale_radius(range=c(1,6)) +
65
      geom_point(aes(size = 1000/ sqrt(train_data$rentPrice)))+
67
      ggtitle("Distribuição dos Imóveis")
```



Modelo

Restrições

- -49 < longitude < -48
- -28 < latitude < -27
- Aluguel Mensal
- Aluguel < R\$ 4000,00
- Número de quartos > 0
- Número de banheiros > 0

Variáveis

- latitude
- longitude
- Número de quartos
- Número de banheiros
- Número de vagas
- Area

Criação do modelo (predict.py)

```
# Load libraries
       import pandas as pd, numpy as np, statsmodels.formula.api as sm
       # Read data
       data = pd.read csv("rentals.csv")
       # Clean data
8
       data =data[(data.rentPeriodId=="MON") & (data.latitude.between(-28, -27)) & (data.longitude.between(-49, -48))
                  & (data.bathrooms > 0) & (data.rooms > 0) & (data.rentPrice <4000) ]
10
11
       data = data[[u'propertyId', u'area', u'rentPrice', u'latitude', u'longitude', u'garages', u'rooms', u'bathrooms']]
       data.describe()
13
       # Explore using pandas
14
15
       # BoxPlot: train data.rentPrice.plot('box')
16
       # Histogram: train data.rentPrice.plot('histogram')
17
18
       # Split data
19
       np.random.seed(42)
       rds = np.random.random(len(data))
20
21
       train_data, test_data = data[rds < 0.7], data[rds >= 0.7]
22
23
       # Simple prediction
24
       result = sm.ols(formula="rentPrice ~ rooms + bathrooms + latitude + longitude + garages + area", data = train_data).fit()
25
       result.summarv()
26
```

Criação do modelo (predict.r)


```
data <- read.csv("rentals.csv")
    data <- data[(data$rentPeriodId=="MON") & data$latitude> -28 & data$latitude < -27 & data$longitude > -49
                  & data$longitude < -48 & data$bathrooms > 0 & data$rooms > 0 & data$rentPrice < 4000 &</pre>
 6
                    !is.na(data$area), ]
    train_indexes <- runif(nrow(data)) < 0.7
 9
    train_data <- data[train_indexes,]
    l <- lm(data = train_data, formula = rentPrice ~ rooms + bathrooms + latitude + longitude + garages + area)</pre>
12
    test_data <- data[!train_indexes,]
14
15
    test_data <- data[!train_indexes,]
    predicted <- predict(l, test_data)</pre>
16
17
    source('visualization.R')
```

Resultados (predict.py)

```
26
       p = result.predict(test_data)
27
       # Plot results
28
       plt.figure()
29
       plt.subplot(211)
30
       plt.plot(test_data.rentPrice, p, 'ro')
31
       plt.xlabel(u"Preco Real")
32
       plt.vlabel(u"Preco Estimado")
33
       plt.title(u"Resultados para set de teste")
34
35
       plt.subplot(212)
36
       plt.hist(np.abs(test_data.rentPrice- p), bins=30 )
       plt.xlabel(u"Número de casos")
37
38
       plt.ylabel(u"Erro absoluto")
```

OLS Regression Results

| Dep. Variable: | rentPrice | R-squared: | 0.608 |
|-------------------|------------------|---------------------|-----------|
| | | | |
| Model: | OLS | Adj. R-squared: | 0.605 |
| Method: | Least Squares | F-statistic: | 202.3 |
| Date: | Tue, 12 Apr 2016 | Prob (F-statistic): | 5.24e-130 |
| Time: | 00:54:20 | Log-Likelihood: | -4939.2 |
| No. Observations: | 658 | AIC: | 9890. |
| Df Residuals: | 652 | BIC: | 9917. |
| Df Model: | 5 | | |
| Covariance Type: | nonrobust | | |




Resultados (predict.R)


Residual standard error: 476.8 on 549 degrees of freedom Multiple R-squared: 0.5536, Adjusted R-squared: 0.5495 F-statistic: 136.2 on 5 and 549 DF, p-value: < 2.2e-16

```
# plot using pure R
par(mfrow=c(2,1))
par(new = F)
plot(test_data$rentPrice ~ predicted,
    xlab = "Valor real (R$)".
    ylab = "Preco estimado (R$)",
     col = 'red',
    main = "Relação entre resultados obtidos")
hist(abs(test_data$rentPrice - predicted),
    breaks = 30,
     c='red',
     xlab = "Erro Absoluto (R$)",
    ylab = "Número de casos",
    main="Erro de medição")
```

Relação entre resultados obtidos




Erro de medição



Resultados (R + ggplot2)

```
library(ggplot2)
    library(multiplot)
    p1 <- ggplot(test_data, aes(x=rentPrice, y=predicted)) +
     xlab("Preço do aluguel") +
     ylab("Preço Estimado") +
32
      geom_point(colour='red') +
33
      ggtitle("Relação entre resultados obtidos")
34
    p2 <- ggplot(test_data, aes(abs(rentPrice- predicted)) ) +
36
      geom_histogram(fill='red', colour='grey') +
     xlab("Erro absoluto") +
37
38
      ylab(" ")
    multiplot(p1, p2, cols=1)
```



O que não discutimos?

- Performance
- Uso no Mercado
- Comunidade
- Dificuldade de aprendizado

Próximos Passos

• Jupyter / JupiteR

Conclusões

Python e R são ferramentas excelentes

para momentos específicos de cada projeto.

Não são excludentes.

Recursos



Código: github.com/ebonet/pythonandr

Exemplos de Matplotlib: http://matplotlib.org/examples/

Exemplos de ggplot2: http://www.cookbook-r.com/Graphs/

Curso online de R: https://www.datacamp.com/courses

Obrigado!

Dúvidas?